2026 年 MathorCup 数学应用挑战赛——大数据竞赛

赛道 A：啤酒酿造化合物分析与啤酒风味预测

啤酒是以麦芽、水为主要原料，添加啤酒花（或酒花制品），经酵母发酵酿制而成的低酒精度发酵酒。发酵过程中除酿酒酵母外，还可能存在非酿酒酵母及细菌等微生物类群，素有“液体面包”之称。它既有麦芽的甜香又有啤酒花的清苦，口感层次丰富，风格千变万化。啤酒风味、口感、香气品质高度依赖酵母、化合物等的物质成分。不同化合物在糖代谢、乙醇耐受、抗逆性、酯类与高级醇合成、以及过量高级醇或醛酮类缺陷物质生成等方面存在显著差异，直接决定啤酒的果香浓度、醇厚程度、纯净度与发酵效率。

附件 1-8 数据是测量了 226 种不同啤酒的化学特性，包括常见的酿造参数，如酒精含量、异α-酸、pH 值、糖浓度，以及 200 多种风味化合物。化合物的很大一部分是来自酒花添加的萜类化合物，负责草本和水果风味；第二大类别是酵母代谢产物，如酯类和醇类，产生水果和溶剂味；其他测量的化合物主要来自麦芽，或其他微生物如非酿酒酵母和细菌（野生菌群）；来自香料或陈化的化合物标记为“其他”。五个属性（热量值、总酸、总酯、酒花香气和硫化合物）由多个单独测量的化合物计算得出。

初赛问题

基于附件中提供的啤酒化合物数据集（商用啤酒风味代谢数据集），要求参赛队伍根据给出的数据进行探索分析，完成以下任务。

问题 1 ：数据缺失条件下的感官评分

以 1.csv 化合物数据为基础，给出 3.xlsx 中定义的 Aroma 与 Flavour 两套、共约 40 个感官维度的 0–6 分制的分级评分结果。

问题 2：化合物–风味分析

利用 2.csv 的化合物相关数据构建化合物共表达图，结合 1.csv 特征，给出每个感官维度的 Top-3 关键因素化合物，并进行稳定性与化学合理性论证。注：稳定性可通过 bootstrap 重采样下 Top-3 入选频率、或不同建模方法间 Top-3 的 Jaccard 系数来量化。

问题 3：风味与"风味指纹"生成

以 tasting_category_fine 为风格标签，学习风格条件生成模型，在给定风格（如 Tripel、Kriek、Lambic）下生成合理的化合物谱，并给出其感官画像；同时做跨风格迁移（如把 Pils/Lager 的化合物谱"迁移"为 Tripel 风格，保持缺陷化合物不恶化）。注：缺陷化合物以所列 DMS/Diacetyl/4VG/trans-2-nonenal/Stale hops 等超阈值项为准。

附件数据说明

附件数据是商用啤酒风味代谢物实测数据集，数据集真实、噪声合理、存在真实缺失值与异常值。详细说明如下：

1.表格 1 是啤酒样本 × 化合物丰度矩阵数据。每行是一个样本，每个样本是一款啤酒，列是化合物丰度。化合物丰度列中，部分数值为原始浓度经对数变换后的结果（负值对应于原始浓度小于 1 的化合物），少量理化参数列（如 ethanol、color、bitterness、pH、CO2）保

留原始量纲。参赛者需自行核实变换底数（log10 或 ln），并明确正负值与原始浓度的对应逻辑。表格 2 是化合物相关性矩阵。行、列都是化合物名，单元格为皮尔逊相关系数。表格 3，4 是感官品评表（目标标签，10 个 sheet），每个 sheet 对应一款啤酒（beer_1~beer_10，对应 Beer# 1~10），是人工感官评分卡，评分采用 0－6 离散等级。表格 4.csv 中的数值不是原始 0－6 分，而是经过标准化/中心化的连续值。表格 5 是风味感官分析数据的相关性矩阵，表格 6 是与 5.csv 配套的另一张相关性矩阵，但变量维度不同，是一张 46 个化学/理化指标×50 个感官属性的交叉相关矩阵（非方阵，行数 46、列数 50，行是化合物/指标，列是感官属性）；表格 7.csv 是原始/标准化样本数据（250 个啤酒样本×187 个感官属性评分），是标准化/中心化后的评分值（有负值，部分列还出现 NA），不是原始 0－6 分制打分。表格 8 为一些综合参考数据。

2．附件数据为给出的数据集，如果参赛队需要更多的数据，可以参考公开数据集

https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information

要求

1.提交完整论文：含摘要、问题分析、数据处理、模型构建、实验结果、结论与建议。

2.支撑材料中提交完整、可复现的源代码。

3.所有图表清晰、结论量化、逻辑完整。